

Laporan Praktikum

Menghitung Frekuensi Kata Menggunakan Python

KMTI21132 - Information Retrieval
Dosen: Salman El Farisi, S.Kom., M.Kom.
Asdos: Elyas Randi Renaldi (0110223277)

Nama	:	Revani
NIM	:	0110224111
Program Studi	:	Teknik Informatika
Rombel	:	TI-11
URL Github Tugas	:	https://github.com/revani18/IR_2025_Revani_3AI01/tree/941e90f2751a12ffee95e8451b915aa8232a2dca/Praktikum01Week04

Jawablah pertanyaan dibawah ini berdasarkan hasil praktikum yang sudah dilakukan:

1. Tuliskan dalam bentuk tabel 10 kata dengan frekuensi tertinggi. Urutkan mulai dari kata dengan frekuensi tertinggi.
2. Tuliskan dalam bentuk tabel 10 kata dengan frekuensi terendah. Urutkan mulai dari kata dengan frekuensi terendah.
3. Tampilkan gambar distribusi frekuensi kata pada korpus “kompas-beritaPart1.xml”
4. Apakah gambar distribusi frekuensi pada korpus “kompas-beritaPart1.xml” mengikuti prinsip distribusi zipf?
5. Tuliskan 10 kata yang menurut kamu janggal / aneh. Menurut kamu, apa penyebabnya?

JAWABAN PERTANYAAN:


1. 10 kata dengan frekuensi tertinggi: `tf_df.head(10)`

Term	Frequency	Rank
yang	6450	1
di	5824	2
dan	4915	3
	4264	4
ini	2744	5
dengan	2625	6
untuk	2583	7
dari	2460	8
itu	2437	9
akan	2055	10

2. 10 kata dengan frekuensi terendah: `tf_df.tail(10)`

Term	Frequency	Rank
katanyapesawat	1	24847
tersebutmemang	1	24848
utarainya	1	24849
ucapnyamananama	1	24850
tersebutsolihin	1	24851
katanyadanyon	1	24852
indonesiaharyadi	1	24853
sipilsementara	1	28454
ke62	1	24855
seoang	1	24856

3. Gambar ini adalah sebuah *scatter plot* yang menunjukkan distribusi frekuensi kata. Sumbu X mewakili peringkat (rank) kata (di mana peringkat 1 adalah kata dengan frekuensi tertinggi), dan sumbu Y mewakili frekuensi (freq) atau jumlah kemunculan kata tersebut.



4. Ya, distribusi frekuensi kata pada korpus “kompas-beritaPart1.xml” mengikuti prinsip Hukum Zipf. Sesuai teori Zipf, frekuensi kata berbanding terbalik dengan peringkatnya ($f \times r \approx \text{konstan}$). Dari grafik terlihat bahwa:
 - Kata paling sering muncul memiliki frekuensi jauh lebih tinggi dibandingkan dengan kata lainnya.
 - Grafik berbentuk kurva menurun tajam (skewed distribution), yang merupakan ciri khas data bahasa alami.

Dengan demikian, hasil praktikum ini sesuai dengan hukum Zipf’s Law seperti yang dijelaskan di modul.
5. Penyebab utamanya karena proses *cleaning* dan *tokenization* belum sepenuhnya menghapus symbol, tag HTML, serta struktur URL dari teks berita.

No	Kata	Penyebab
1	nbsp	Hasil konversi HTML () tidak dibersihkan saat preprocessing
2	br	Tag HTML () ikut terbaca sebagai kata
3	http	URL berita tidak dibersihkan
4	com	Pecahan dari domain situs (Kompas.com)
5	nbspnbspnbsp	Artefak karakter ganda HTML
6	xml	Terbaca dari tag XML file
7	nqtchq	Potongan ID berita dari link republika
8	xlvi	Angka romawi dari halaman berita
9	read	Potongan URL (/read/news/...)
10	nbspn	Noise akibat encoding teks XML